



UNIVERSIDAD DE CHILE  
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS  
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

EXPLORANDO EL POTENCIAL DE LAS REDES NEURONALES DE GRAFOS  
PARA EXTRAER INFORMACIÓN DE BGP

TESIS PARA OPTAR AL GRADO DE  
MAGÍSTER EN COMPUTACIÓN

MEMORIA PARA OPTAR AL TÍTULO DE  
INGENIERO EN COMPUTACIÓN

VALENTINA FRANCISCA ESTEBAN LAGOS

PROFESORA GUÍA:  
IVANA BACHMANN ESPINOZA

PROFESOR CO-GUÍA:  
SEBASTIÁN FERRADA

MIEMBROS DE LA COMISIÓN:  
NOMBRE UNO  
NOMBRE DOS  
NOMBRE TRES

SANTIAGO DE CHILE  
2024

# Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aequale doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquid aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguere possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facere et urbane Stoicos irridere, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius. Ego autem mirari satis non queo unde hoc sit tam insolens domesticarum rerum fastidium. Non est omnino hic docendi locus; sed ita prorsus existimo, neque eum Torquatum, qui hoc primus cognomen invenerit, aut torquem illum hosti detraxisse, ut aliquam ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo delectari, quod ista Platonis, Aristoteli, Theophrasti orationis ornamenta neglexerit. Nam illud quidem physici, credere aliquid esse minimum, quod profecto numquam putavisset, si a Polyaeno, familiari suo, geometrica discere maluisset quam illum etiam ipsum dedocere. Sol Democrito magnus videtur, quippe homini erudito in geometriaque perfecto, huic pedalis fortasse; tantum enim esse omnino in nostris poetis aut inertissimae segnitiae est aut fastidii delicatissimi. Mihi quidem videtur, inermis ac nudus est. Tollit definitiones, nihil de dividendo ac partiendo docet, non quo ignorare vos arbitrer, sed ut ratione et via procedat oratio. Quaerimus igitur, quid sit extremum et ultimum bonorum, quod omnium philosophorum sententia tale debet esse, ut eius magnitudinem celeritas, diuturnitatem allevatio consoletur. Ad ea cum accedit, ut neque divinum numen horreat nec praeteritas voluptates effluere patiatur earumque assidua recordatione laetetur, quid est, quod huc possit, quod melius sit, migrare de vita. His rebus instructus semper est in voluptate esse aut in armatum hostem impetum fecisse aut in poetis evolvendis, ut ego et Triarius te hortatore facimus, consumeret, in quibus hoc primum est in quo admirer, cur in gravissimis rebus non delectet eos sermo patrius, cum.

*dedicatoria.*

# Agradecimientos

a mi por soportar?

# Índice

<b>1. Introducción</b>	<b>1</b>
1.1. Motivación	2
1.2. Hipótesis	3
1.3. Objetivos	3
1.3.1. Objetivo general	3
1.3.2. Objetivos específicos	3
1.4. Metodología	4
1.5. Contribuciones	4
1.6. Estructura del trabajo	4
<b>2. Marco Teórico</b>	<b>5</b>
2.1. Grafos	5
2.2. Inteligencia Artificial	5
2.3. Redes Neuronales	6
2.3.1. Funciones de Activación	8
2.3.2. Función de Pérdida	8
2.3.3. Entrenamiento	8
2.3.3.1. Sampling	8
2.3.3.2. Regularización	8
2.3.3.3. Optimización	8
2.3.3.4. Dropout	8
2.3.4. evaluación	8
2.3.4.1. Métricas de evaluación	8
2.3.5. Tipos de Redes Neuronales	8
2.3.6. Redes Neuronales Feed For (FFNN)	8
2.3.7. Redes Neuronales Recursivas (RNN)	9
2.3.8. Redes Neuronales Convolucionales (CNN)	9
2.3.9. Graph Neuronla Network (GNN)	10
2.3.9.1. Message Passing Neural Networks (MPNN)	11
2.3.9.2. Graph Convolution Network (GCN)	11
2.3.9.3. Graph Attention Network (GAT)	12
2.3.9.4. GraphSAGE	12
2.4. Procesamiento de datos	12
2.4.1. Balance de clases	12
2.4.2. Aumento de datos	12

2.5. Internet .....	12
2.5.1. Ruteo .....	13
2.5.2. Ruteo Internet .....	14
2.5.3. Ruteo Interno .....	14
2.5.3.1. Routing Information Protocol (RIP) .....	14
2.5.3.2. Open Shortest Path First (OSPF) .....	14
2.5.3.3. Enhanced Interior Gateway Routing Protocol (EIGRP) .....	14
2.5.3.4. Intermediate System to Intermediate System (IS-IS) .....	14
2.5.4. Ruteo Externo .....	14
2.5.4.1. Border Gateway Protocol (BGP) .....	15
<b>3. Datos .....</b>	<b>16</b>
3.1. RIPE NCC .....	16
3.2. CAIDA .....	16
3.3. ROUTE VIEWS .....	16
<b>4. Experimentos .....</b>	<b>17</b>
4.1. Experimento 1: .....	17
4.2. Experimento 2: .....	17
4.3. Resultados y Analisis .....	17
<b>Bibliografía .....</b>	<b>19</b>
<b>Anexo A. titulo anexo 1 .....</b>	<b>20</b>

# Índice de Tablas

# Índice de Ilustraciones

Figura 4.1: El gatito más bello del mundo. ....	18
---	----



# Capítulo 1

## Introducción

En la sociedad actual el Internet juega un papel esencial en la vida cotidiana, facilitando la comunicación, la colaboración y el intercambio de información. En los últimos años, su uso y desarrollo ha crecido exponencialmente, convirtiéndose en una herramienta indispensable. Esta creciente interconexión global ha hecho que las redes sean fundamentales para el funcionamiento de la sociedad moderna. En este contexto, es crucial entender cómo está formado el Internet, ya que conocer su funcionamiento y estructura permite preservar su integridad y eficiencia. Además, garantizar un funcionamiento continuo y óptimo.\

El Internet está conformado por miles de Sistemas Autónomos (SA) interconectados entre sí. Cada SA consiste en un conjunto de IPs que comparten un mismo protocolo de enrutamiento y están administradas por una misma entidad, como proveedores de servicios de Internet (ISP), empresas comerciales, universidades, entre otros. A cada uno de estos Sistemas Autónomos se le asigna un número y prefijos de direcciones IP, los cuales anuncia a sus vecinos a través del Border Gateway Protocol (BGP). BGP es un protocolo dinámico de enrutamiento externo en el que los SA anuncian sus tablas de ruteo y cambios en sus AS-Paths para alcanzar direcciones IP específicas. De esta manera, cada SA recibe estos anuncios de todos sus vecinos BGP y toma decisiones sobre la mejor forma de direccionar sus paquetes. \

Dentro del grafo de Sistemas Autónomos que conforma Internet, el camino que un paquete recorre de un nodo a otro no suele ser el más corto debido a los acuerdos comerciales que cada SA, como entidad independiente, establece con sus vecinos. Estos acuerdos se clasifican en tres tipos de relaciones: 1) Provider-to-customer (P2C), en el cual el cliente paga al SA proveedor para que este enlace permita el tráfico de sus paquetes hacia el resto de Internet. 2) Peer-to-peer (P2P), donde los SA intercambian tráfico entre sí y con sus clientes, pero no con sus proveedores u otros pares. 3) Sibling-to-sibling (S2S), cuando dos

SA pertenecen al mismo dominio. Gao [1] propuso reglas para modelar estas relaciones entre SA, que reflejan cómo suelen configurarse en BGP, lo que permite inferir las posibles rutas seleccionadas por este protocolo. Sin embargo, estas soluciones se basan principalmente en el cálculo de heurísticas. Por otro lado, estudios más recientes como el de Shapira y Shavitt cite{UnveilingtheTypeRelationshipBetweenAutonomousSystemsUsingDeepLearning} proponen técnicas de Deep Learning, creando representaciones de los SA que luego son utilizadas en una Red Neuronal.\

Aquí entra en juego un nuevo enfoque que podría cambiar nuestra forma de analizar datos: el uso de Redes Neuronales de Grafos (GNNs). Las GNNs están diseñadas específicamente para trabajar con datos organizados en forma de grafos. Al ser Redes Neuronales, tienen la capacidad de encontrar representaciones efectivas de la información y descubrir patrones en datos estructurados de esta manera. A diferencia de las Redes Neuronales convencionales, las GNNs pueden aprovechar la información de los nodos vecinos, lo que les permite entender mejor la estructura del grafo y realizar análisis más detallados.\

Así nace esta tesis, con el objetivo de explorar el comportamiento de las Redes Neuronales de Grafos (GNNs) utilizando datos de BGP para representar Internet y las relaciones entre los Sistemas Autónomos que lo componen. Esta área es aún poco explorada y presenta varias dificultades, principalmente debido a la necesidad de aplicar conocimiento tanto en redes como en Deep Learning. En particular, obtener una representación precisa de la topología de Internet requiere comprender a fondo el funcionamiento del protocolo BGP y saber cómo y dónde obtener datos, que no siempre están disponibles públicamente. Así como también tener un conocimiento de teoría de grafos y Deep Learning necesario al momento de la implementación de un modelo de GNNs y diferentes técnicas para la tarea requerida.

## 1.1 Motivación

**(está copiado el problema, es similar pero revisar de cambiar la forma en cómo se plantea)**

El problema a abordar mediante esta investigación radica en la necesidad crítica de comprender, medir y evaluar la degradación en la calidad de servicio de Internet en situaciones específicas donde los nodos de la red experimentan desconexiones. En la actualidad, Internet se ha convertido en un componente esencial para individuos y organizaciones en todo el mundo, desempeñando un papel fundamental en la vida cotidiana y en el funcionamiento de diversas aplicaciones y servicios críticos.

La resiliencia de Internet, entendida como su capacidad para mantener la calidad de servicio incluso en condiciones desafiantes, se ve comprometida cuando los nodos experimentan desconexiones. Esta situación se traduce en fenómenos perjudiciales como la pérdida de paquetes, retrasos en la transmisión de datos y fluctuaciones en el rendimiento, todos los cuales impactan directamente en la calidad de la experiencia del usuario. La investigación busca explorar a fondo estas situaciones, clasificando distintos escenarios de desconexión y definiendo métricas específicas para evaluar cómo se manifiesta la degradación en la QoS en cada caso.

La investigación se propone analizar y clasificar diversas situaciones de desconexión, elegir métricas específicas para evaluar la QoS, realizar pruebas realistas en un simulador, y comparar enfoques existentes.

## **1.2 Hipótesis**

Las Redes Neuronales de Grafos (GNNs) pueden ofrecer un rendimiento superior en comparación con las metodologías del estado del arte para la inferencia del tipo de relación entre Sistemas Autónomos.

## **1.3 Objetivos**

### **1.3.1 Objetivo general**

El objetivo principal de este estudio es evaluar diversas arquitecturas de Redes Neuronales de Grafos (GNNs) para determinar su viabilidad en la inferencia del tipo de relación de tráfico entre dos Sistemas Autónomos. Esto se logrará mediante el análisis de características específicas de cada Sistema Autónomo, la información de actualizaciones BGP, la topología y los cambios en esta.

### **1.3.2 Objetivos específicos**

1. Obtención de datos: Recopilar datos de fuentes confiables como

que correspondan a Sistemas Autónomos representativos de la Red de Internet. Esto implica obtener datos sobre nodos, características y relaciones entre ellos. Asimismo, obtener información relevante sobre flujos de paquetes BGP.

- Preparación de datos: Mejorar la calidad de los datos mediante el uso de técnicas de normalización, conversión de atributos categóricos a numéricos, manejo de desequilibrio de clases, entre otros. Además, construir el grafo y definir cómo se proporcionarán los datos de entrada a nuestros modelos GNNs.

1. Diseño e implementación de modelos: Diseñar e implementar modelos GNN y framework específicos que permita la inferencia del tipo de relación que dos Sistemas Autónomos comparten.
2. Evaluación de performance: Comparar el desempeño de diferentes arquitecturas de GNNs en las inferencias, identificando los parámetros de mayor relevancia.
3. Análisis de resultados: Comprender los resultados obtenidos mediante el estudio y la comparación con los valores esperados y estado del arte

## **1.4 Metodología**

## **1.5 Contribuciones**

## **1.6 Estructura del trabajo**

la tesis está organizada de la siguiente manera:

- capítulo 2 blabla
- capítulo 3 blablabla
- capítulo 4 no existe todavía

# Capítulo 2

## Marco Teórico

### 2.1 Grafos

Un grafo (Figura X) es una estructura discreta formada a partir del conjunto de vértices (también conocido como nodos) y aristas las cuales son las uniones entre estas [1]. De forma más sencilla un grafo es una representación visual de una relación binaria. Un grafo  $G$  se caracteriza mediante la pareja de conjuntos  $(V, E)$  donde  $V$  es el conjunto no vacío de vértices y  $E$  denota el conjunto de aristas, este último es, a su vez, es un conjunto de pares de nodos. Así, la definición de un grafo está dada por  $G = (V, E)$ . Usamos  $v_i \in V$  para denotar que un nodo forma parte del grafo y  $e_{ij} = (v_i, v_j) \in E$  para indicar que existe una arista entre el nodo  $v_i$  y  $v_j$ . Cada nodo  $v_i$  tiene vecinos con los cuales comparte una arista, estos se representan de la forma  $N(v_i) = \{v_j \in V : (i, j) \in E\}$ . El número de vértices y aristas en un grafo se representan mediante  $n = |V|$  y  $m = |E|$ .

### 2.2 Inteligencia Artificial

Inteligencia Artificial (IA) es un campo de la informática que busca simular el comportamiento de la inteligencia humana, es decir, intenta replicar y automatizar la capacidad del

ser humano para tomar decisiones.

Dentro del área de la Inteligencia Artificial, nos encontramos con el Machine Learning, disciplina que a través del desarrollo de algoritmos y modelos busca que las máquinas aprendan

patrones por medio de la experiencia, la cual incluye datos de entrenamiento y retroalimentación. El objetivo es entrenar una máquina para una tarea específica sin la necesidad de

programar explícitamente un algoritmo. Finalmente, dentro de Machine Learning se encuentra el campo de Deep Learning, un área

que se centra en el uso de arquitecturas de Redes Neuronales profundas para aprender representaciones de datos de manera jerárquica. A diferencia de Machine Learning convencional,

donde las características se extraen manualmente de los datos y se proporcionan al modelo,

en Deep Learning, estas representaciones se aprenden de forma automática mientras el modelo lleva a cabo la tarea asignada. Una característica distintiva de esta disciplina es el uso de

Redes Neuronales, estructuras compuestas por múltiples capas entre la entrada y la salida. Cada capa procesa la información y extrae características cada vez más abstractas a medida que se profundiza en la Red. Permitiéndole al modelo así capturar patrones y características complejas en los datos.

PONER IMAGEN:JERARQUIA CONCEPTUAL ENTRE INTELIGENCIA ARTIFICIAL, MACHINE LEARNING Y DEEP LEARNING

## 2.3 Redes Neuronales

Una Red Neuronal es un modelo computacional compuesto de neuronas (perceptrones),

dispuestas en capas y conectadas entre sí con el fin de aprender patrones mediante el intercambio de información ponderada por pesos. Estos pesos se ajustan en base a los datos

de entrada, asignando valores en función del reconocimiento de patrones, que permiten una salida esperada. En una Red Neuronal, cada unidad toma entradas, las pondera por separado, suma los

valores y pasa esta suma a través de una función para producir una salida, la cual es comparada con otras neuronas a las cuales está conectada. El perceptrón, que funciona como una

representación matemática de una unidad básica en la Red, realiza cálculos para determinar tendencias en los datos de entrada, asignándole diferentes pesos a cada valor de entrada en base a patrones entre los datos para realizar tareas específicas.

IMAGEN:ARQUITECTURA BASICA DE UNA RED NEURONAL FULLY CONNECTED DE UNA CAPA

Un perceptrón está compuesto por cuatro elementos distintivos (Figura 4), i) los valores de entrada definidos como  $x_1, x_2, \dots, x_{n-1}, x_n$  donde cada  $x_j$  corresponde a un vector de tamaño  $d$ , ii) los pesos

definidos como  $w_j \in W_{n \times d}$  donde  $W$  corresponde a la matriz de pesos los cuales son ajustados durante la etapa de entrenamiento de la Red, iii) la suma  $z = \sum_{j=1}^n w_j x_j + b$  y iv) la función de activación, la cual establece un umbral de salida para evitar que los valores de salida se disparen. Esta función de activación permite incluir más capas y, por ende, mayor complejidad en las arquitecturas de redes que se construyan. Las funciones de activación tienen la capacidad de mejorar el aprendizaje de patrones en los datos [20]. Algunas de las funciones de activación comúnmente empleadas incluyen la Sigmoide, la Tangente Hiperbólica ( $\tanh$ ), la Rectified Linear Unit (ReLU) y la Leaky ReLU.

IMAGEN: ESTRUCTURA GENERAL DE UN PERCEPTRON

La técnica comúnmente utilizada para el entrenamiento de Redes Neuronales es el back-propagation, que tiene como objetivo ajustar los pesos de los parámetros de la Red para

minimizar la función de pérdida [22]. Esta función cuantifica la diferencia entre las predicciones hechas y los valores reales. Una vez que se ha calculado la pérdida, el proceso de

optimización se centra en modificar los pesos para mejorar la precisión general de la Red. Durante el entrenamiento de las Redes Neuronales, se emplea el descenso de gradiente, un método que implica el cálculo de la derivada de la función de pérdida con respecto a los pesos de la Red. Este cálculo determina la dirección y magnitud en la que los parámetros de

un modelo deben ser ajustados para minimizar la función de pérdida. Por ende, es fundamental que esta función sea continua y derivable. En problemas de regresión, se suele utilizar

funciones como el Mean Squared Error y Mean Absolute Error, mientras que en problemas de clasificación, destaca la Cross-Entropy Loss.

### **2.3.1 Funciones de Activación**

### **2.3.2 Función de Pérdida**

### **2.3.3 Entrenamiento**

#### **2.3.3.1. Sampling**

#### **2.3.3.2. Regularización**

#### **2.3.3.3. Optimización**

#### **2.3.3.4. Dropout**

### **2.3.4 evaluación**

#### **2.3.4.1. Metricas de evaluación**

### **2.3.5 Tipos de Redes Neuronales**

### **2.3.6 Redes Neuronales Feed For (FFNN)**

También conocida como `multilayer perceptrons`, esta arquitectura representa la forma más simple y fundamental de una Red Neuronal, sirviendo como la base de la mayoría de los modelos de Deep Learning. En esta arquitectura la información fluye exclusivamente hacia adelante'', sin bucles o conexiones hacia atrás.

El flujo de información comienza en la capa de entrada, donde se reciben los datos, seguida de las capas ocultas (`hidden layers` en ingles), siendo las Fully Connected las más comunes (Figura `fully-connected`), donde cada neurona está conectado a cada neurona de la capa anterior. De esta manera, las salidas de cada perceptrón generan una salida que, al estar conectada con otros nodos, funcionan como entrada para la siguiente capa, continuando así hasta llegar a la capa de salida.



El objetivo principal de una Red Feed Forward es aproximar alguna función  $f(x)$ . Por ejemplo, en un problema de regresión, se busca modelar la relación  $y = f(x)$ .

### 2.3.7 Redes Neuronales Recursivas (RNN)

Las Redes Neuronales Recurrentes (RNN) son una variante de las Redes Neuronales Feed Forward, diferenciándose por su capacidad para retener y utilizar información previa, es decir, poseen «memoria». A diferencia de las Redes Neuronales Feedforward convencionales, que asumen que los datos de entrada en cada capa son independientes entre sí, las Redes Neuronales Recurrentes (RNN) introducen conexiones entre las salidas previas y la salida actual, generando así un proceso de retroalimentación. Esta característica en las RNN las hace particularmente eficientes para trabajar con datos

secuenciales, como en aplicaciones de procesamiento del lenguaje natural incluyendo traducción, generación de texto y la predicción de series temporales.

IMAGEN: ARQUITECTURA BASICA DE UNA RED NEURONA RECURRENTE

La imagen de arriba es una representación simple de una Red Neuronal Recurrente (Figura 5). En el lado izquierdo se encuentra la notación abreviada  $y_t$  y, en el lado derecho, la notación desplegada para representar RNNs. Donde  $x_t$  es un vector que representa la entrada en el instante de tiempo  $t$ . A el estado oculto con el paso del tiempo  $t$  y actúa como la “memoria” de la Red, calculando en función del estado oculto anterior y la entrada en el paso actual.

### 2.3.8 Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales (Figura 6) son un tipo especializado de modelo de Red Neuronal diseñado especialmente para procesar información en forma de grilla [14]. Su aplicación principal se encuentra en el análisis de imágenes, en el reconocimiento de objetos, clases y categorías. Las CNN se componen de una capa de entrada, una capa de salida y varias capas ocultas intermedias. Estas capas ocultas llevan a cabo operaciones de convolución, lo que les permite aprender características específicas de las imágenes. En el proceso de convolución, se aplican filtros, a través de matrices de pesos. Estos filtros aprenden a detectar diversas características como bordes, patrones, colores, entre otros. Así a medida que se avanza en las capas de la CNN, la red es capaz de reconocer elementos más complejos.

Figura 6: Estructura de un modelo de Convolutional Neural Network con tres capas convolucionales.

### 2.3.9 Graph Neuronla Network (GNN)

Las GNN son una arquitectura de Redes Neuronales especialmente diseñada para realizar predicciones basadas en datos representativos de grafos. A diferencia de las Redes Neuronales convencionales, las GNNs reciben datos en forma de tensores que pueden representar nodos, atributos de nodos, aristas y atributos de aristas. Existen diferentes enfoques, dependiendo de la tarea de aprendizaje que se quiere llevar a cabo, estos son:

- Nivel de nodo: Incluye tareas como clasificación, regresión y clustering de nodos. Se realizan inferencias a partir de las conexiones con otros nodos.
- Nivel de aristas: Se abordan tareas de clasificación y predicción de aristas. Por ejemplo, determinar la existencia de una relación entre dos nodos.
- Nivel de grafo: Se encuentran tareas de clasificación, regresión y matching de grafos para las cuales el modelo debe ser capaz de aprender una representación para el grafo completo. Las GNN tienen una serie de ventajas sobre las Redes Neuronales convencionales cuando se trabaja con datos de grafos. En contraste con los modelos tradicionales, las GNN aprovechan las relaciones entre las entidades que conforman los datos de entrada a el modelo. Estas relaciones pueden incluir aspectos como orden, jerarquía, dependencias o relaciones de otro tipo que son comunes en grafos y se representan a través de las aristas que conectan los nodos. En cuanto a la adaptabilidad a variaciones en el tamaño de entrada, las Redes Neuronales convencionales requieren que los datos de entrada mantengan un mismo tamaño. Para ello, recurren a técnicas como padding o broadcast, los cuales no tienen efectos significativos en el desempeño de los modelos. Las GNNs, por su parte, ofrecen flexibilidad para adaptarse a distintos tamaños de entrada [11]. Otro motivo para optar por GNNs es su capacidad para manejar el isomorfismo de los grafos, es decir dos grafos pueden lucir diferentes, pero ser estructuralmente iguales. Un modelo tradicional trataría ambos grafos como si fuesen datos diferentes, sin embargo, no lo son. Esto es comparable a lo que sucedería si se le presenta como entrada dos imágenes donde una se encuentra invertida. Es por esta razón que no se puede trabajar directamente con una matriz de adyacencia en una Red Feed Forward, ya que es sensible a estos cambios. Las GNNs utilizan técnicas que son invariantes ante permutaciones, lo que permite trabajar con el isomorfismo en grafos.

Finalmente, el último desafío radica en que la estructura de un grafo no puede ser reducida a un espacio euclidiano, y su conceptualización no puede limitarse a una distancia

euclidiana [18]. A diferencia de Redes Neuronales que trabajan, por ejemplo, con imágenes, las cuales pueden ser interpretadas como un grafo, la representación de la información se puede entender en términos de píxeles en un espacio bidimensional. Así, la esencia detrás del uso de GNNs radica en su capacidad de entrenar un modelo que pueda procesar un grafo, sus nodos y relaciones, logrando identificar patrones relevantes en la topología

para lograr de forma efectiva la tarea asignada. Por ejemplo, en el ámbito de las redes sociales, las GNNs pueden ser utilizadas para clasificar usuarios según sus interacciones, identificando así grupos afines. Otra aplicación puede ser la recomendación de contenido de interés de un usuario, basándose en sus conexiones y preferencias históricas. En el campo de la biología, es posible predecir el tipo de moléculas basándose en sus características estructurales y propiedades. El diseño de una GNN se hace por medio de la combinación de diferentes módulos:

- **Módulo de propagación:** Este módulo se utiliza para propagar información entre los nodos capturando tanto la topología como los atributos de los nodos. Esto se logra combinando los datos de cada nodo con los de sus vecinos.
- **Módulo de muestreo:** Cuando los grafos son muy grandes, se utiliza generalmente un módulo de muestreo con el fin de seleccionar un subconjunto del grafo, aportando de este modo en la capacidad de generalización de un modelo y reducción de complejidad. Se combina generalmente con un módulo de propagación.
- **Módulo de pooling:** Cuando se necesita representaciones de subgrafos se utiliza este módulo para extraer información de los nodos. Se utiliza para reducir la dimensionalidad de las representaciones de nodos.

Un modelo GNN se construye generalmente combinando estos módulos. A continuación (Figura 7), se ilustra el pipeline de una arquitectura GNN. El modelo recibe como entrada un grafo, y en la capa GNN, se emplea un operador convolucional, un módulo de muestras y una operación skip-connection que se fusionan para propagar la información y extraer detalles de alto nivel mediante el módulo de pooling. Después de pasar por todas las capas intermedias, se obtiene una salida en forma de embeddings, a los cuales se les aplica una función de pérdida para obtener los resultados del ajuste del modelo en base a la tarea asignada.

Figura 7: Pipeline básico de una arquitectura GNN.

### 2.3.9.1. Message Passing Neural Networks (MPNN)

### 2.3.9.2. Graph Convolution Network (GCN)

Es un tipo específico de MPNN, donde se utilizan convoluciones de grafos para agregar información de los nodos adyacente de un nodo en un grafo.

La operación de convolución en el grafo produce la suma normalizada de las características de los nodos vecinos [2]. Esta normalización garantiza que la información agregada sea ponderada correctamente, es decir, evitar que un nodo con gran cantidad de vecinos tenga una representación desproporcionada y que luego tenga una influencia mayor en la representación otros nodos en las siguientes capas.

La notación de los embeddings de los nodos  $h_i^{\{(l+1)\}}$  en la capa  $l + 1$  de la red está dado por:

### 2.3.9.3. Graph Attention Network (GAT)

Otra variante de MPNN son las Graph Attention Networks (GAT). A diferencia de una Red Neuronal de Convolución, GAT incorpora un mecanismo de atención que permite que cada nodo pondere de forma diferenciada, indicando la importancia de las representaciones de cada vecino para la actualización de las características de un nodo `cite{GAT}`.

Los coeficientes se calculan por un mecanismo el cual calcula un puntaje para cada par de nodos. Luego estos puntajes se normalizan por medio de la función SoftMax (Figura `ref{calculoGAT}`).

Así tenemos:

```
begin{figure}[h] centering includegraphics[width=10cm]{imagenes/GAT.png} caption{Pipeline del mecanismo de cálculo de las ponderaciones para una GAT.} label{calculoGAT} end{figure}
```

### 2.3.9.4. GraphSAGE

## 2.4 Procesamiento de datos

### 2.4.1 Balance de clases

### 2.4.2 Aumento de datos

## 2.5 Internet

Antes de abordar la definición de Internet, es crucial comenzar definiendo qué es una Red. Se trata de un conjunto de computadoras conectadas entre sí, que posibilita el intercambio de datos. En este contexto, una red puede ser visualizada como un grafo, donde los nodos representan los computadores y las aristas simbolizan las conexiones entre ellos que permiten el envío de mensajes.

En el caso de Internet, se define como una extensa red creada mediante la interconexión de redes más pequeñas conocidas como Sistemas Autónomos (AS), los que consisten en grupos de máquinas interconectadas que comparten un mismo protocolo de enrutamiento. Estos AS están gestionadas por diversas organizaciones, que pueden ser desde proveedores de acceso a Internet (ISP), grandes empresas tecnológicas, universidades o incluso agencias gubernamentales. A cada AS, se le asigna un número único conocido como ASN, el cual es

utilizado para identificar al AS. Además, a cada AS se le asigna un conjunto de direcciones IP del cual es responsable que le lleguen los paquetes.

La conexión entre computadoras y redes en Internet se establece a través de cables, ondas de radio y otras formas de infraestructura. Los datos transmitidos por estas conexiones se traducen en bits, los cuales, al ser leídos por una computadora, se descodifican y se interpretan como un mensaje.

Es relevante destacar que los datos transmitidos a través de redes informáticas se dividen en paquetes, que pueden ser subdivisiones de paquetes más grandes. Cada paquete consta de dos partes: el mensaje en sí y el encabezado. Este último contiene información importante, como las direcciones de destino y origen, así como valores que indican si es un paquete es un fragmento de un mensaje más grande, entre otros detalles. El encabezado de un paquete permite que, una vez que el paquete alcanza su destino, pueda ensamblarse adecuadamente si es necesario.

### **2.5.1 Ruteo**

El ruteo consiste en la elección de caminos que seguirá un paquete dentro de una red, con el propósito de garantizar que la información que se transmite por Internet pueda llegar a su destino mediante la ruta más eficiente. Una red está formada por múltiples máquinas a las cuales se les llama nodo y las rutas que las unen. La comunicación entre dos nodos de la red se puede establecer mediante la interconexión de diferentes caminos, permitiendo así, conectar dos nodos que no tienen una conexión directa por medio de nodos intermedios. De esta forma el enrutamiento es el proceso de seleccionar la mejor ruta entre estos nodos en base a algún parámetro o reglas.

Un enrutador o router es un dispositivo de red que se conecta a otros dispositivos y redes. Son los encargados de seleccionar las rutas que irán tomando los datos enviados.

El ruteo opera gracias a las tablas de rutas presentes en los routers y a la información proporcionada en los encabezados de los paquetes, los cuales contienen datos sobre el destino del paquete. Cuando llega un paquete a un router, se consulta la tabla de enrutamiento para localizar la dirección destino, y posteriormente dirigir el paquete al próximo router o punto de red.

Para ilustrar esto, supongamos un usuario accede a una página web desde su hogar. En este escenario, los paquetes viajan desde el computador hasta el router de su casa. Este router luego examina el encabezado del paquete para identificar el destino final en su tabla

de rutas y lo envía al siguiente punto en red. Este nuevo punto será el encargado de realizar nuevamente el proceso de redirigir el paquete. Este procedimiento se repite en todos los routers hasta que finalmente el paquete llega al destino final.

Existen dos tipos de enrutamiento: estático y dinámico. El enrutamiento estático implica el uso de tablas estáticas, las cuales deben ser modificadas manualmente para cambiar su configuración. Es útil en situaciones donde los parámetros de red permanecen constantes. Por otro lado, en el enrutamiento dinámico, los routers se encargan de ir actualizando las tablas de enrutamiento en tiempo real, ajustándolas según las condiciones de la red. Este proceso se lleva a cabo mediante los protocolos de enrutamiento.

## **2.5.2 Ruteo Internet**

Se encarga de gestionar las rutas a seguir de un paquete dentro de un Sistema Autónomo. En este contexto los routers ocupan protocolos de enrutamiento interno para intercambiar la información del estado de la red y las rutas disponibles. Entre los protocolos de ruteo interno se tiene:

`begin{itemize}` item OSPF (Open Shortest Path First): Utiliza el algoritmo de Dijkstra para determinar las rutas más cortas entre nodos `cite{OSPF}`. item RIP (Routing Information Protocol): Utiliza un enfoque de vector de distancia para calcular la ruta más optima, basándose en la cantidad de saltos `cite{RIP}`. `end{itemize}`

## **2.5.3 Ruteo Interno**

### **2.5.3.1. Routing Information Protocol (RIP)**

### **2.5.3.2. Open Shortest Path First (OSPF)**

### **2.5.3.3. Enhanced Interior Gateway Routing Protocol (EIGRP)**

### **2.5.3.4. Intermediate System to Intermediate System (IS-IS)**

## **2.5.4 Ruteo Externo**

Se centra en la gestión de rutas entre los diferentes Sistemas Autónomos que conforman el Internet. En este caso, se usan protocolos de enrutamiento externo, que al igual que los protocolos de enrutamiento interno se encarga de intercambiar la información de las rutas disponibles, permitiendo así que paquetes viajen de manera más efectiva. Algunos protocolos de enrutamiento externos son:

begin{itemize} item BGP (Border Gateway Protocol): Tiene un enfoque de vector de distancia. Utiliza un enfoque de vector de distancia y toma decisiones basadas en políticas de red para intercambiar información eficientemente cite{RFC-BGP}. item IS-IS (Intermediate System to Intermediate System): Protocolo de enrutamiento de estado de enlace, similar a OSPF cite{IS-IS}. end{itemize}

#### 2.5.4.1. Border Gateway Protocol (BGP)

El Border Gateway Protocol (BGP) es un protocolo de enrutamiento externo, que se utiliza para intercambiar información de rutas entre los diferentes Sistemas Autónomos que conforman el Internet (Figura ref{BGP-SA} ). Toma decisiones de enrutamiento basadas en políticas, reglas de Red y el camino más corto (AS PATH) cite{RFC-BGP}.

El protocolo BGP comienza con un handshake, el cual se hace entre dos vecinos BGP, donde los AS se ponen de acuerdo en cuanto a configuraciones y soporte que tendrán por ejemplo si soportaran IPv4 o IPv6 o ambas. Una vez establecida la conexión estas intercambian información mediante UPDATES donde se pueden agregar o quitar caminos. De este modo, los vecinos actualizarán sus tablas de rutas y propagarán estos mismos cambios a sus vecinos.

De este, modo BGP elige caminos mediante la determinación del camino más corto según saltos entre AS para llegar a su destino, sin embargo, esta métrica para determinar el siguiente salto de un paquete no toma en cuenta factores como congestión o velocidad de conexión al momento de seleccionar una ruta.

begin{figure}[h] centering includegraphics[width=15cm]{imagenes/topologiaBGP.png}  
caption{Grafo de una red con 5 Sistemas Autónomos con 4 direcciones IP cada uno. }  
label{BGP-SA} end{figure}

# Capítulo 3

## Datos

### 3.1 RIPE NCC

### 3.2 CAIDA

### 3.3 ROUTE VIEWS



# Capítulo 4

## Experimentos

### 4.1 Experimento 1:

### 4.2 Experimento 2:

### 4.3 Resultados y Analisis




Figura 4.1: El gatito más bello del mundo.

# Bibliografía

- [1] S. H., Z., Y. Z. L. L. W. C. L. M. S. Jie Zhou Ganqu Cui, «Graph neural networks: A review of methods and applications», 2018.
- [2] M. W. Thomas N. Kipf, «SEMI-SUPERVISED CLASSIFICATION WITH GRAPH CONVOLUTIONAL NETWORKS», 2017.

# Anexo A

## titulo anexo 1

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aequale doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquid aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguere possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius. Ego autem mirari satis non queo unde hoc sit tam insolens domesticarum rerum fastidium. Non est omnino hic docendi locus; sed ita prorsus existimo, neque eum Torquatum, qui hoc primus cognomen invenerit, aut torquem illum hosti detraxisse, ut aliquam ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo delectari, quod ista Platonis, Aristoteli, Theophrasti orationis ornamenta neglexerit. Nam illud quidem physici, credere aliquid esse minimum, quod profecto numquam putavisset, si a Polyaeno, familiari suo, geometrica discere maluisset quam illum etiam ipsum dedocere. Sol Democrito magnus videtur, quippe homini erudito in geometriaque perfecto, huic pedalis fortasse; tantum enim esse omnino in nostris poetis aut inertissimae segnitiae est aut fastidii delicatissimi. Mihi quidem videtur, inermis ac nudus est. Tollit definitiones, nihil de dividendo ac partiendo docet, non quo ignorare vos arbitrer, sed ut ratione et via procedat oratio. Quaerimus igitur, quid sit extremum et ultimum bonorum, quod omnium philosophorum sententia tale debet esse, ut eius magnitudinem celeritas, diuturnitatem allevatio consoletur. Ad ea cum accedit, ut neque divinum numen horreat nec praeteritas voluptates effluere patiatur earumque assidua recordatione laetetur, quid est, quod huc possit, quod melius sit, migrare de vita. His rebus instructus semper est in voluptate esse aut in armatum hostem impetum fecisse aut in poetis evolvendis, ut ego et Triarius te hortatore facimus, consumeret, in quibus hoc primum est in quo admirer, cur in gravissimis rebus non delectet eos sermo patrius, cum.